

Modelo GARCH(p, q)

Modelo utilizado en serie temporales financieras

Diego Astaburuaga & David Rivas

¹Universidad Técnica Federico Santa María. Departamento de matemática.

21 de Noviembre de 2023



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones
- 6 Referencias



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones
- 6 Referencias



Algunas características de las series temporales financieras son [1]:

- 1 No estacionariedad de la serie de precios.
- 2 Ausencia de autocorrelación para las variaciones de precios.
- 3 Autocorrelaciones de los rendimientos al cuadrado de los precios.
- 4 Agrupación de la volatilidad.
- 5 Distribuciones con colas anchas.
- 6 *Leverage effect*.
- 7 Estacionalidad.



Ejemplo: Rendimientos Diarios S&P 500

El **índice S&P 500**, que abarca las principales 500 empresas en la bolsa estadounidense, se presenta como una serie relevante para el análisis con **modelos GARCH**.




Figura: Serie de tiempo de los rendimientos diarios del S&P 500. Fuente: `arch.data.sp500` en Python.



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones
- 6 Referencias



Modelos GARCH: Aspectos Fundamentales

- Desarrollados por **Robert F. Engle** en 1982 (ARCH) y posteriormente generalizados por **Tim Bollerslev** en 1986 (GARCH), los Modelos GARCH abordan la volatilidad en series temporales financieras.
- Permiten modelar series de tiempo con ruidos de varianza no constante.
- Capturan la dinámica de rendimientos del mercado, destacando en la modelización de volatilidad condicional.
- Utilizados para comprender y prever fenómenos como el agrupamiento de volatilidad, ofreciendo una herramienta esencial en finanzas.



Modelo ARCH: Definición

Definición del Modelo ARCH(p)

Sea ϵ_t un proceso estocástico discreto de valores reales. El proceso ϵ_t sigue un modelo ARCH(p) (AutoRegressive Conditional Heteroscedasticity) si:

$$\epsilon_t | F_{t-1} \sim \mathcal{N}(0, \sigma_t^2),$$
$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2$$

donde $p \geq 0$, $\omega > 0$, $\alpha_i \geq 0$ para $i = 1, \dots, p$. Donde F_{t-1} denota la información hasta el momento $t - 1$.



Tengamos en cuenta que buscamos modelar una varianza, por ende es razonable utilizar lo siguientes puntos

- Debe cumplirse que $\omega > 0$ y $\alpha_i \geq 0$ para $i = 1, \dots, p$.
- Se suele pedir que $\alpha_j > \alpha_i$ para $j > i$ bajo la interpretación de que las noticias más recientes tienen más impacto.
- La **condición de estacionaridad** viene dada por

$$0 \leq \sum_{i=1}^p \alpha_i \leq 1$$



Modelo GARCH: Definición

Definición del Modelo GARCH(p, q)

Sea ϵ_t un proceso estocástico discreto de valores reales. Entonces ϵ_t sigue un modelo GARCH(p, q) (Generalized AutoRegressive Conditional Heteroscedasticity) si y sólo si:

$$\epsilon_t | F_{t-1} \sim \mathcal{N}(0, \sigma_t^2),$$

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

donde $p \geq 0$, $q \geq 0$, $\omega > 0$, $\alpha_i \geq 0$ para $i = 1, \dots, p$, y $\beta_j \geq 0$ para $j = 1, \dots, q$. Donde F_{t-1} denota la información hasta el momento $t - 1$.



Modelo GARCH: Comentarios

- α_i : Controla la **contribución de los errores pasados** a la varianza condicional en Modelos GARCH(p, q).
- β_j : Controla la contribución de la varianza pasada a la varianza condicional. Un valor más alto indica una mayor **persistencia en la varianza** a lo largo del tiempo.
- Se menciona que ϵ_t se les suele conocer como **retornos** y σ_t^2 como **volatilidad**.
- La **condición de estacionaridad** para este modelo viene dada por la ecuación

$$\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j < 1$$



Ejemplo GARCH(1,1) no estacionario

En caso de que no se cumpla la **condición de estacionaridad**, la volatilidad puede tender a infinito como se observa en el siguiente ejemplo simulado:




Figura: Fuente: Elaboración propia.



Representación de modelos GARCH(p, q)

Resultado

Bajo la notación anterior, escriba $\nu_t = \epsilon_t^2 - \sigma_t^2$

$$\epsilon_t^2 = \omega + \sum_{i=1}^r (\alpha_i + \beta_i) \epsilon_{t-i}^2 + \nu_t - \sum_{j=1}^q \beta_j \nu_{t-j}, \quad t \in \mathbb{Z}$$

donde $r = \max\{p, q\}$ bajo la condición de que $\alpha_i = 0$ ($\beta_j = 0$) para $i > p$, ($j > q$).

El resultado anterior¹ nos dice que la serie de los residuos al cuadrado puede ser entendida como un modelo ARMA(r, q), en específico, para el modelo ARCH(p), se tiene que este se puede representar como un AR(p).

¹Este resultado es fundamental para toda la sección de inferencia.



Modelo ARMA-GARCH

La implementación de un modelo GARCH suele ser acompañada por un modelo ARIMA para la serie, por ejemplo un proceso ARMA(2, 1) – GARCH(1, 1) puede ser definido mediante:

$$\begin{cases} X_t - 0.8X_{t-1} + 0.8X_{t-2} = \epsilon_t - 0.8\epsilon_{t-1} \\ \epsilon_t = \sigma_t \eta_t, \quad \eta_t \text{ iid } N(0, 1) \\ \sigma_t^2 = 1 + 0.2\epsilon_{t-1}^2 + 0.6\sigma_{t-1}^2 \end{cases}$$

lo que permite desarrollar complejos más complejos que capten la heterocedasticidad.



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones
- 6 Referencias



Identificación del modelo

- Detectar si el proceso cuenta con un ruido blanco débil o fuerte (supuesto distribucional, *Portmanteau tests*).
- Utilizar test de homocedasticidad: *Lagrange Multiplier Test for Conditional Homoscedasticity*
- Identificar parámetros P, Q del modelo $ARMA(P, Q)$ (*The Corner Method*).
- Determinar parámetros de la parte GARCH.



Existen principalmente dos métodos para la estimación de los parámetros:

- **Estimación mediante mínimos cuadrados.**

- ① Mínimos Cuadrados Ordinarios.
- ② Mínimos Cuadrados Generalizados Factibles.
- ③ Mínimos Cuadrados Ordinarios con Restricciones.

- **Estimación cuasi-máxima verosímil.**

para más información de métodos, resultados importantes, aplicaciones, etc, revise [1].



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos**
- 5 Conclusiones
- 6 Referencias



Ejemplo: Rendimientos Diarios S&P 500

En **Python** es de bastante utilidad conocer la librería **ARCH** en [3] que entrega gran soporte de modelos ARCH, de sus variantes y extensiones. Además de la librería **statsmodels** en [2] para análisis de series de tiempo en general. Recordemos el ejemplo inicial




Figura: Serie de tiempo de los rendimientos diarios del S&P 500. Fuente: `arch.data.sp500` en Python.



Ejemplo: Rendimientos Diarios S&P 500

A modo de ejemplo, se ajusta un modelo GARCH(1, 1) para obtener los **residuos estandarizados** y la **volatilidad condicional**:




Figura: Residuos y volatilidad condicional.



Ejemplo: Rendimientos Diarios S&P 500

Los detalles del modelo vienen dados por:

```
Constant Mean - GARCH Model Results
=====
Dep. Variable:      Adj Close    R-squared:          0.000
Mean Model:         Constant Mean  Adj. R-squared:      0.000
Vol Model:          GARCH         Log-Likelihood:     -6936.72
Distribution:        Normal       AIC:                13881.4
Method:             Maximum Likelihood  BIC:                13907.5
                                           No. Observations:   5030
Date:               Sun, Nov 19 2023  Df Residuals:         5029
Time:               19:21:31          Df Model:            1
                                           Mean Model
=====
              coef    std err          t      P>|t|      95.0% Conf. Int.
-----
mu           0.0564   1.149e-02    4.906   9.302e-07 [3.384e-02,7.887e-02]
Volatility Model
=====
              coef    std err          t      P>|t|      95.0% Conf. Int.
-----
omega        0.0175   4.683e-03    3.738   1.854e-04 [8.328e-03,2.669e-02]
alpha[1]     0.1022   1.301e-02    7.852   4.105e-15 [7.665e-02, 0.128]
beta[1]      0.8852   1.380e-02   64.125   0.000      [ 0.858, 0.912]
=====
Covariance estimator: robust
```

Figura: Resumen del modelo ajustado.



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones**
- 6 Referencias



Existen múltiples extensiones y variantes de los modelos presentados, entre las mostradas en la bibliografía:

- Basados en asimetría:
 - 1 *Exponential GARCH Model (EGARCH).*
 - 2 *Threshold GARCH Model (TGARCH).*
 - 3 *Asymmetric Power GARCH Model (APARCH).*
 - 4 *A GARCH Model with Contemporaneous Conditional Asymmetry.*
- Modelos multivariados.



- Existen series de tiempo que no verifican los supuestos de modelos ya existentes (ej: ϵ_t de varianza constante).
- Utilizar modelos GARCH y ARCH para series temporales financieras permite captar los cambios de la volatilidad y otros fenómenos de interés.
- Se requiere conocer bien el problema a estudiar para identificar que tipo de modelo usar y que especificaciones debe tener.



Contenido

- 1 Motivación
- 2 Modelos ARCH(p) y GARCH(p, q)
- 3 Inferencia en modelos GARCH(p, q)
- 4 Aplicación sobre datos
- 5 Conclusiones
- 6 Referencias**



Bibliografía recomendada

La presentación desarrollada se basó fuertemente en el siguiente libro:




Figura: Libro: GARCH MODELS.



- [1] C. Francq y J.M. Zakoian. *GARCH Models: Structure, Statistical Inference and Financial Applications*. Wiley, 2011. ISBN: 9781119957393. URL: <https://books.google.cl/books?id=hwR1aWSg9PUC>.
- [2] Skipper Seabold y Josef Perktold. “statsmodels: Econometric and statistical modeling with python”. En: *9th Python in Science Conference*. 2010.
- [3] Kevin Sheppard et al. *bashtage/arch: Release 6.2.0*. Ver. v6.2.0. Sep. de 2023. DOI: 10.5281/zenodo.8380532. URL: <https://doi.org/10.5281/zenodo.8380532>.



Fin de la presentación.

¡Muchas gracias por la atención!

